



Aynı dizi, farklı bağlam: CRISPR-Cas9 hedef dışı tahmininde bağlam-duyarlı çizge temsili

Graph C, aynı fiziksel hedefi farklı hedef-gözlem bağlamlarıyla temsil eder.

Özet

CRISPR-Cas9, hedef DNA'yı rehber RNA (sgRNA) ile eşleştirerek keser; diziyi benzeyen istem dışı bölgelerde hedef dışı aktivite görülebilir. Bu riski önceden kestirmek, güvenli rehber RNA tasarımının önkoşuludur. Bu çalışma, hedef dışı aktiviteyi bağlam duyarlı çizge sinir ağlarıyla inceler. Değerlendirme sızıntıya karşı denetlenmiş, rehber RNA'ya göre ayrık (guide-disjoint) ve yalnızca ölçülmüş veri evreni üzerine kuruludur. Katkı, bağlamların hangi ekseninde sinyal verdiğini açık konumlandırmaktır; sıralamada güçlü XGBoost F4 referansı korunur; karar eşiğinde ise nadir ölçülmüş negatifleri doğru negatif tanıma davranışı belirginleşir.

Anahtar kelimeler: CRISPR-Cas9, hedef dışı tahmin, çizge sinir ağları, hedef-gözlem bağlamları, ölçülmüş veri.

Ana bulgu

Bağlam katkısı bir AUPRC zaferi olarak değil, karar eşiğinde nadir negatif davranışı olarak okunur.

310142 →
25632 → **1702**
veri akışı
aday, ölçülmüş evren, test

0.992338
XGBoost F4
AUPRC çıktısı

110/169
doğru negatif
karar eşiği davranışı

Sızıntıya karşı denetlenmiş sözleşme

Graph C hedef-gözlem temsili

Özellik grubu encoder'ı


Nadir negatif karar davranışı

Giriş ve Amaç

CRISPR-Cas9 hedef dışı kesim riski, rehber RNA'nın güvenli kullanımını sınırlar. Dizi benzerliği önemli bir sinyaldir; ancak aynı fiziksel hedef, farklı deneysel ve epigenetik bağlamlarda farklı gözlemler taşıyabilir. Bu nedenle soru yalnızca "hangi hedef dizi benziyor?" değildir. Asıl soru, aynı hedefin hangi ölçüm bağlamında, hangi karar davranışına yol açtığıdır. Graph C bu fikri hedef-gözlem düğümüyle temsil eder.

Graph C hedef-gözlem temsili


Rehber RNA ayrık değerlendirme




Şekil 2. Graph A/B/C semantik karşılaştırması. Graph C, aynı fiziksel hedefi farklı hedef-gözlem bağlamlarıyla temsil eder; oklar biyolojik nedensellik göstermez.

Bulgular

Sonuçlar iki ayrı soruyu yanıtlar. Sıralama ekseninde AUPRC ölçülür: güçlü tablo temelli referans XGBoost F4 en sağlam çıta olarak kalır (AUPRC 0.992338; %95 aralık [0.950179, 0.999336]). En iyi tekil GNN olan S8B_R2 yaklaşık (0.986020; [0.929981, 0.998966]); aralıklar fark yokluğu ile uyumludur ve bu bir eşdeğerlik iddiası değildir. Karar eşiği ekseninde nadir sınıf negatiftir. Doğru negatif sayısı aynı payda üzerinden okunur: XGBoost F4 40, Graph C GCN 14, Graph C GATv2 63, özellik gruplarını ayrı işleyen encoder 110 / 169. MCC ve specificity bu davranışı görünür kılan metriklerdir; kazanım seed/rehber RNA duyarlıdır.



Şekil 3. İki eksenli bulgular: sıralama (AUPRC) ve karar eşiği (MCC/specificity). AUPRC birincil sıralama metriğidir; 0.900705 no-skill PR baseline'dır.



Şekil 4. Karar eşiğinde nadir negatif tanıma: 169 ölçülmüş negatif üzerinden doğru negatif sayıları. Sonuçlar validation-kilitli ve seed/rehber RNA duyarlıdır.

Okuma. Sıralamada (AUPRC) güçlü tablo temelli referans XGBoost F4 en sağlam çıta olarak kaldı; bağlamların katkısı sıralamada değil, karar eşiğinde ortaya çıkıyor.

Tablo 1. Karar eşiğinde doğru negatif ve specificity değerleri: XGBoost F4 40 (0.236), Graph C GCN 14 (0.083), Graph C GATv2 63 (0.373), özellik grubu encoder'ı 110 (0.651).

Sıralama

Pozitif prevalansı 0.900705 olduğu için güçlü modeller AUPRC'de yüksek bölgede kümelenir.

Karar eşiği

Aynı 169 negatif paydasında doğru negatif sayısı bağlam katkısını daha görünür kılar.

Sınır

Bu davranış validation-kilitli, seed/rehber RNA duyarlı ve dış doğrulama gerektirir.

Önerilen Yaklaşım ve Mimari

Veri sözleşmesi

İkili etiket Scheme A ile tanımlanır: cleavage_freq > 1e-5. Doğrulanmamış adaylar (measured=0) test doğrusu yapılmaz.


Değerlendirme yalnızca ölçülmüş veri evreninde, rehber RNA'ya göre ayrık bölünmeyle ve test üzerinde ayar yapılmadan yürütülür. Model ve karar eşiği seçimi validation kümesinde kilitlenir.

Family-aware Graph C GATv2

Ana çözüm Graph C üzerinde, özellik ailelerini ayrı kodlayan family-aware hedef bağlam encoder'ı ve edge-aware GATv2 katmanlarıdır. Graph C aynı fiziksel hedefi hedef-gözlem düğümlerine ayırır; 212 kolonluk hedef-gözlem vektörü hedef dizi one-hot, deneysel epigenetik, nükleozom özetleri ve missingness ailelerinde kodlanır.

Rehber RNA ve hedef-gözlem temsilleri iki GATv2 katmanından geçer. S5F2 mismatch/enerji özellikleri hem attention kenar özneteliği hem de son edge classifier girdisi olarak korunur; FiLM ve S1 late-fusion dalları Sprint 8 uzantılarıdır.

Family-aware Graph C GATv2 S5F2 edge-aware attention FiLM/S1 late fusion



Şekil 1. Önerilen yaklaşımın kodla uyumlu mimarisi: family-aware Graph C GATv2, hedef-gözlem bağlamları dört özellik ailesinde kodlar; S5F2 edge özellikleri GATv2 attention ve edge classifier hatında korunur.


Tartışma ve Sonuç

Sıralama bol sayıda pozitifte (prevalans 0.900705) doyuma ulaşır; karar eşiği ise az sayıdaki negatife bakar. 169 negatif yalnızca 9 rehber RNA'da yoğunlaşır; 80'i rehber RNA 9251 üzerindedir. Farkın da, kırılabilirliğin da kaynağı bu kıtlıktır.

Diğer çalışmalarla ham skor kıyası yapılmaz; veri, bölünme ve prevalans farklıdır. Konumlandırma skor yanılsı değil, soru ve sözleşme karşılaştırmasıdır.

Yorum

- Bağlam etkisi sıralamada değil, karar eşiğinde konumlanır.
- Graph C GCN düşük kaldığı için sonuç monoton çizge kazanımı değildir.
- Model içi açıklamalar davranış kanıtıdır; biyolojik nedensellik kanıtı değildir.



Şekil 5. Literatürde nitel konumlandırma (A+B). Ham skor leaderboard kurulmaz; kıyas soru ve sözleşme karşılaştırmasıdır.

Sınırı açık değerlendirme Nadir negatif karar davranışı

Katkı ve Sınırlar

Katkılar

- Ölçülmüş veri evreni ve rehber RNA ayrık test sözleşmesi.
- Graph C ile hedef-gözlem bağlamları.
- Sıralama ve karar eşiğini ayrı okuyan değerlendirme.

Sınırlar

- AUPRC üstünlüğü iddia edilmedi.
- Kazanım validation-kilitli ve seed/rehber RNA duyarlıdır.
- Daha fazla ölçülmüş negatif ve dış doğrulama gerekir.

Referanslar

- [1] Kipf, T. N., Welling, M. Semi-Supervised Classification with Graph Convolutional Networks. 2017.
- [2] Vinodkumar vd. Prediction of sgRNA Off-Target Activity in CRISPR/Cas9 Gene Editing Using Graph Neural Networks. 2021.
- [3] Liu vd. Graph-CRISPR: A Gene Editing Efficiency Prediction Model Based on Graph Neural Networks. 2025.
- [4] Chuai vd. DeepCRISPR: Optimized CRISPR Guide RNA Design by Deep Learning. 2018.

- [5] Lin vd. CRISPR-Net: A Recurrent Convolutional Network Quantifies CRISPR Off-Target Activities. 2020.
- [6] Gao vd. Data Imbalance in CRISPR Off-Target Prediction. 2020.
- [7] Guan vd. A Systematic Method for Solving Data Imbalance in CRISPR Off-Target Prediction. 2024.